

Data Lake

Repositorio de grandes volúmenes de datos estructurados y no estructurados para análisis y procesamiento.

Concepto

Data Lakes almacenan formatos variados, muchas veces antes del modelado analítico final.

Sitio y documentación oficiales

Use como referencia principal la fuente oficial de Data Lake: <https://aws.amazon.com/what-is/data-lake/>. La documentación oficial debe ser la primera fuente para instalación, versiones compatibles, cambios de sintaxis y nuevas funciones.

Riesgos

Schema drift, duplicados, particiones incorrectas, permisos y datos tardíos son riesgos comunes.

QA

Valide ingestión, metadatos, particiones, volumen, transformaciones y acceso.

Lake vs Warehouse

Data Lake prioriza flexibilidad/datos brutos; Data Warehouse organiza datos modelados para análisis.

Cuándo utilizarlo

Utilice este conocimiento cuando el riesgo, la arquitectura o la etapa de entrega requieran este tipo de validación. Confirme objetivo, ambiente, datos necesarios y evidencias esperadas antes de comenzar.

Cómo lo aplica QA

Parta del comportamiento o riesgo que debe validarse, prepare datos y ambiente, ejecute la técnica o herramienta de forma reproducible y registre evidencias que ayuden al equipo a comprender el resultado.

Qué es y dónde encaja

Data Lake es una herramienta o tecnología que puede apoyar actividades de Quality Engineering. Antes de adoptarla, entienda qué problema resuelve, dónde entra en el flujo y qué evidencia o ganancia de productividad debe producir.

Cómo comenzar con seguridad

Comience por el sitio y la documentación oficial de Data Lake. Confirme prerequisites, versiones compatibles, sistema operativo y permisos. Practique en un ambiente controlado antes de usarla en un flujo crítico.

Primer uso orientado a QA

Elija una tarea pequeña y verificable en Data Lake, configure solo lo necesario, ejecute un ejemplo simple y confirme el resultado. Repita con otros datos o condiciones antes de agregar abstracciones.

Uso en un proyecto real

Defina dónde entra Data Lake, quién mantiene la configuración, cómo se manejan credenciales y datos y cómo se comparten resultados. Integre la herramienta al flujo del equipo.

Buenas prácticas de adopción

Estandarice versiones y configuración, documente decisiones, evite secretos en el código y mantenga ejemplos reproducibles. Revise periódicamente si Data Lake sigue entregando valor.

Problemas comunes y troubleshooting

Cuando Data Lake falle, confirme versiones, dependencias, permisos, conectividad, datos y ambiente antes de concluir que existe un defecto del producto. Conserve el error original y reduzca el problema al menor caso reproducible.