

Data Lake

Repositorio de grandes volúmenes de datos estructurados y no estructurados para análisis y procesamiento.

Concepto

Data Lakes almacenan formatos variados, muchas veces antes del modelado analítico final.

Riesgos

Schema drift, duplicados, particiones incorrectas, permisos y datos tardíos son riesgos comunes.

QA

Valide ingestión, metadatos, particiones, volumen, transformaciones y acceso.

Lake vs Warehouse

Data Lake prioriza flexibilidad/datos brutos; Data Warehouse organiza datos modelados para análisis.

Cuándo utilizarlo

Utilice este conocimiento cuando el riesgo, la arquitectura o la etapa de entrega requieran este tipo de validación. Confirme objetivo, ambiente, datos necesarios y evidencias esperadas antes de comenzar.

Cómo lo aplica QA

Parta del comportamiento o riesgo que debe validarse, prepare datos y ambiente, ejecute la técnica o herramienta de forma reproducible y registre evidencias que ayuden al equipo a comprender el resultado.

Consejo de QA

Pruebe también metadatos y particiones; archivos presentes no garantizan un dataset utilizable.

Recursos oficiales

Site oficial: <https://aws.amazon.com/what-is/data-lake/>