

Data Lake

Repositorio de grandes volúmenes de datos estructurados y no estructurados para análisis y procesamiento.

Concepto

Data Lakes almacenan formatos variados, muchas veces antes del modelado analítico final.

Riesgos

Schema drift, duplicados, particiones incorrectas, permisos y datos tardíos son riesgos comunes.

QA

Valide ingestión, metadatos, particiones, volumen, transformaciones y acceso.

Lake vs Warehouse

Data Lake prioriza flexibilidad/datos brutos; Data Warehouse organiza datos modelados para análisis.

QA Tip

Pruebe también metadatos y particiones; archivos presentes no garantizan un dataset utilizable.