

Data Lake

Repositório de grande volume de dados estruturados e não estruturados para análise e processamento.

Conceito

Data Lakes armazenam dados em formatos variados, frequentemente antes de modelagem analítica final.

Riscos

Schema drift, duplicidade, partições incorretas, permissões, dados atrasados e qualidade de ingestão são riscos comuns.

QA

Valide ingestão, metadados, partições, volume, regras de transformação e acesso.

Lake x Warehouse

Data Lake privilegia flexibilidade e dados brutos; Data Warehouse normalmente organiza dados modelados para consumo analítico.

QA Tip

Teste também metadados e partições; arquivos presentes não garantem que o dataset esteja utilizável.