

Data Lake

Repositório de grande volume de dados estruturados e não estruturados para análise e processamento.

Conceito

Data Lakes armazenam dados em formatos variados, frequentemente antes de modelagem analítica final.

Riscos

Schema drift, duplicidade, partições incorretas, permissões, dados atrasados e qualidade de ingestão são riscos comuns.

QA

Valide ingestão, metadados, partições, volume, regras de transformação e acesso.

Lake x Warehouse

Data Lake privilegia flexibilidade e dados brutos; Data Warehouse normalmente organiza dados modelados para consumo analítico.

Quando usar

Use este conhecimento quando o risco, a arquitetura ou a etapa do ciclo de desenvolvimento exigir validação específica. Antes de aplicar, confirme objetivo, ambiente, dados necessários e evidências esperadas.

Como o QA aplica na prática

Comece pelo comportamento ou risco que precisa ser validado, prepare dados e ambiente, execute a técnica ou ferramenta de forma reproduzível e registre evidências que permitam explicar o resultado ao time.

Dica de QA

Teste também metadados e partições; arquivos presentes não garantem que o dataset esteja utilizável.

Recursos oficiais

Site oficial: <https://aws.amazon.com/what-is/data-lake/>